

Proyecto final

Alejandra Abaunza Suárez

June 4, 2026

1 Definición del problema

Para este proyecto se seleccionó el desastre de Brumadinho Dam en Brasil ocurrido el 25 de enero de 2019. Este desastre ocurrió debido a que un muro de contención se derrumbó abruptamente a lo largo del borde de un estanque con material de desecho parecido al lodo de una mina brasileña. El derrumbe de la mina Córrego do Feijão, en el sureste del estado de Minas Gerais, liberó un torrente de residuos que rápidamente arrasaron edificios, casas, etc.[1]

2 Área de estudio + Mapa localizador

El área de estudio se localiza en Brumadinho, en el estado de Minas Gerais, Brasil. Esta región pertenece a una zona minera caracterizada por actividad extractiva intensiva.

Se definió un área de interés (ROI) que incluye:

- La presa de residuos colapsada.
- El río Paraopeba.
- Las áreas afectadas por el flujo de lodo.

3 Adquisición de datos

Las imagen satelital fue obtenida desde el Copernicus Programme mediante la plataforma Copernicus Data Space Browser. Se utilizaron datos del satélite Sentinel-2, específicamente productos Level-2A. Se seleccionó una imagen que corresponde a una fecha cercana al evento del colapso: 01 de febrero de 2019



Figure 1: Área de estudio definida.

3.1 Metadata de la imagen

- Name: *S2A_MSIL2A₂0190201T131241_N0500_R138_T23KNT₂0221206T064832.SAFE*
- Size: 1138MB
- Sensing time: 2019-02-01T13:12:41.024000Z
- Platform short name: SENTINEL-2
- Instrument short name: MSI

4 Creación del dataset

El conjunto de datos fue construido a partir de imágenes Sentinel-2 utilizando QGIS y Semi-Automatic Classification Plugin (SCP). El proceso fue el siguiente:

- Reproyección de las bandas B5, B6, B7 y B11 a 10m.
- Selección de la región de interés (ROI) sobre la imagen satelital.
- Creación de polígonos de entrenamiento para diferentes clases de cobertura (agua, vegetación, lodo, construcción).
- Asignación de etiquetas de clase (macroclass y class_id) a cada polígono.
- Extracción de valores espectrales de las bandas B2, B3, B4, B5, B6, B7, B8 y B11.
- Exportación de los datos en formato TSV para su uso en Python.

Adicionalmente, para evitar sobreestimación del desempeño, la partición entre entrenamiento y prueba se realizó a nivel de ROI (Region of Interest). De esta manera, los píxeles pertenecientes a un mismo polígono de entrenamiento nunca aparecen simultáneamente en ambos conjuntos. Este procedimiento permite evaluar la capacidad de generalización espacial de los modelos.

5 Descripción del Dataset

El conjunto de datos está compuesto por información espectral a nivel de píxel. Las bandas utilizadas son:

- B2 (Azul)
- B3 (Verde)
- B4 (Rojo)
- B5, B6, B7 (Red Edge)
- B8 (Infrarrojo cercano)
- B11 (Infrarrojo de onda corta)

El dataset contiene las siguientes columnas:

- Coordenadas: Latitude, Longitude
- Bandas espectrales: B2, B3, B4, B5, B6, B7, B8, B11
- Etiqueta de clase: Class (1- Vegetacion Bosque, 2 - edificios, 3 - Vegetación campo, 4 - Lodo, 5 - Agua río)

6 Modelos de Clasificación Evaluados

Se implementaron cinco algoritmos de aprendizaje supervisado:

- Decision Tree (DT)
- Support Vector Machine (SVM)
- Artificial Neural Network (ANN - MLP)
- K-Nearest Neighbors (KNN)
- Naive Bayes (NB)

7 Resultados de Evaluación

La evaluación se realizó utilizando una separación espacial por ROI. Para cada una de las cinco clases se reservaron polígonos completos para el conjunto de prueba, obteniendo un total de 400 muestras para entrenamiento y 100 muestras para validación.

Los resultados muestran que las firmas espectrales de las cinco clases son altamente discriminables, aunque existe cierta confusión entre las clases correspondientes a vegetación y lodo en algunos modelos.

7.1 Matriz de Confusión

La mejor clasificación fue obtenida por el modelo SVM. Su matriz de confusión fue:

```
[[20  0  0  0  0]
 [ 0 20  0  0  0]
 [ 0  0 20  0  0]
 [ 0  3  0 17  0]
 [ 0  0  0  0 20]]
```

Se observa que la principal fuente de error corresponde a tres muestras de la clase 4 (lodo) clasificadas como clase 2 (edificios).

7.2 Tabla Comparativa de Modelos

Modelo	OA	Kappa	Precision	Recall	F1
SVM	0.97	0.9625	0.9739	0.97	0.9698
ANN (MLP)	0.96	0.9500	0.9667	0.96	0.9596
KNN	0.95	0.9375	0.9600	0.95	0.9492
Naive Bayes	0.95	0.9375	0.9600	0.95	0.9492
Decision Tree	0.94	0.9250	0.9488	0.94	0.9393

Table 1: Comparación de desempeño de los modelos supervisados utilizando validación espacial por ROI.

7.3 Métricas de Evaluación

El mejor desempeño fue obtenido por el clasificador Support Vector Machine (SVM), alcanzando una exactitud global (OA) de 97%, un coeficiente Kappa de 0.9625, una precisión ponderada de 0.9739, un recall de 0.97 y un F1-score de 0.9698.

La red neuronal artificial (ANN) obtuvo resultados muy cercanos, con una OA de 96% y un F1-score de 0.9596. Los modelos KNN y Naive Bayes alcanzaron una OA de 95%, mientras que el árbol

de decisión obtuvo una OA de 94%.

Las diferencias entre modelos son relativamente pequeñas, lo que indica que las cinco clases definidas presentan firmas espectrales bien diferenciadas en las bandas Sentinel-2 utilizadas.

8 Predicción Raster Final

Una vez identificado el modelo con mejor desempeño, correspondiente a Support Vector Machine (SVM), se procedió a realizar la clasificación de todos los píxeles del área de estudio mediante inferencia sobre el stack multibanda Sentinel-2.

Durante esta etapa, las ocho bandas espectrales utilizadas en el entrenamiento (B2, B3, B4, B5, B6, B7, B8 y B11) fueron empleadas como variables de entrada para el modelo. Cada píxel del raster fue tratado como una observación independiente y clasificado en una de las cinco categorías definidas previamente.

El modelo fue aplicado sobre un raster multibanda de dimensiones 431 filas por 1119 columnas, correspondiente a un total de 482289 píxeles. Después de excluir los valores NoData, se clasificaron 460577 píxeles válidos.

El resultado fue exportado como un archivo GeoTIFF georreferenciado conservando el sistema de referencia espacial y la transformación afín originales de la imagen Sentinel-2.

9 Mapa Temático Clasificado

La Figura 2 muestra el resultado final de la clasificación supervisada obtenida mediante el modelo SVM.




Figure 2: Mapa temático generado a partir de la clasificación supervisada del área de estudio.

10 Cuantificación Espacial

A partir del raster clasificado se calculó la superficie ocupada por cada categoría de cobertura. Considerando una resolución espacial de 10 m por píxel, se estimó el área total clasificada y la proporción correspondiente a cada clase.

Clase	Píxeles	Área (ha)	Área (km ²)	%
Bosque	194892	1948.92	19.49	42.31
Construcciones	119405	1194.05	11.94	25.92
Vegetación campo	106395	1063.95	10.64	23.10
Lodo	33837	338.37	3.38	7.35
Agua	6048	60.48	0.60	1.31
Total	460577	4605.77	46.06	100.00

Table 2: Distribución espacial de las clases obtenidas mediante clasificación supervisada.

11 Análisis de Resultados

Los resultados obtenidos muestran que el modelo SVM fue el clasificador con mejor desempeño, alcanzando una exactitud global de 97%, un coeficiente Kappa de 0.9625 y un F1-score de 0.9698.

La separación por ROI durante la fase de validación permitió evaluar la capacidad de generalización del modelo evitando que muestras provenientes de una misma región estuvieran presentes simultáneamente en entrenamiento y prueba. Esto proporciona una evaluación más realista del desempeño del clasificador.

El mapa temático generado evidencia una predominancia de áreas cubiertas por vegetación, que representan aproximadamente el 65% de la superficie clasificada. Por otra parte, las zonas identificadas como lodo ocupan aproximadamente 3.38 km², reflejando el impacto espacial del colapso de la presa de Brumadinho.

Los resultados demuestran que las bandas espectrales de Sentinel-2 contienen información suficiente para discriminar adecuadamente entre vegetación, construcciones, agua y depósitos de lodo asociados al desastre.

12 Conclusiones

En este proyecto se aplicaron técnicas de clasificación supervisada sobre imágenes Sentinel-2 para analizar el área afectada por el desastre de Brumadinho, Brasil. Se evaluaron cinco algoritmos de aprendizaje automático, siendo Support Vector Machine (SVM) el modelo con mejor desempeño, alcanzando una exactitud global de 97%, un coeficiente Kappa de 0.9625 y un F1-score de 0.9698.

El modelo seleccionado fue utilizado para generar un mapa temático de cobertura terrestre y cuantificar el área ocupada por cada clase. Los resultados demostraron la capacidad de los datos Sentinel-2 y de los métodos de aprendizaje supervisado para identificar y cartografiar diferentes coberturas, incluyendo las zonas afectadas por el lodo generado por el colapso de la presa.

References

- [1] NASA Earth Observatory. “Another deadly dam collapse in brazil.” Accessed: Apr. 16, 2026. [Online]. Available: <https://science.nasa.gov/earth/earth-observatory/another-deadly-dam-collapse-in-brazil-144501/>.